Shark Attacks Collector

LANCER LE PROJET EN 5 MINUTES
1. Ouvrir ou cloner le dépôt GitHub Shark Attacks Collector.
2. Installer Python 3.11+ et les dépendances de **requirements.txt**.
3. Télécharger le dataset Kaggle **« Sharks Attack collector »** (Global Shark Attack File / GSAF) depuis la page Kaggle utilisée, le renommer **global_shark_attacks_raw.csv** et le placer dans **data/raw/**.
4. Depuis la racine : **python -m src.pipeline**, puis **python -m pytest -q**.
Sans export réel, le jeu synthétique de 121 lignes valide le parcours local.

01 · Question et périmètre

Où et quand les incidents de requins sont-ils déclarés ?
Dans quelles conditions environnementales les signalements surviennent-ils ?
Que peut-on tester sans confondre association, cause et risque individuel ?

FAIT OBSERVÉ · dernier run réel de référence
6 890 entrées -> 6 687 acceptées, 194 rejetées et 9 doublons retirés (PASS). Ces nombres décrivent un export ponctuel, pas le risque de morsure ni l'ensemble des incidents réels.

Ce que je cherche à produire

Je construis un pipeline reproductible qui transforme les déclarations GSAF en fichiers contrôlés et indicateurs descriptifs, puis teste avec prudence des pistes environnementales. Aucune API ne fournit la cause d'une attaque.

Utilisateurs et indicateurs

Je vise un étudiant, un enseignant ou un analyste qui veut choisir des lieux et des périodes à examiner, pas calculer un risque individuel. Je fournis au moins trois indicateurs : comptes par pays/localité/année, saisonnalité mensuelle, et tests environnementaux exploratoires avec leur statut.

Besoin	Indicateur livré
Choisir des lieux ou périodes à examiner	Comptes par pays, localité, année et mois
Comparer une saisonnalité	Mois, avec sensibilité aux dates du 1er janvier
Formuler des pistes environnementales	H1-H5, tests et statuts explicites

Sources et précautions

Source	Apport	Précaution
« Sharks Attack collector » (GSAF via Kaggle)	Incidents déclarés	Export ponctuel; droits de redistribution à vérifier.
GBIF	Occurrences géographiques	Présence observée, pas abondance ni identification d'attaque.
Nominatim / OSM	Géocodage de lieux	Centre-ville possible; pas une position GPS d'incident.
NOAA OISST / ERDDAP	SST quotidienne et anomalie	Grille 0,25°; vérifier les métadonnées avant collecte complète.
Open-Meteo Archive	Air, pluie et vent	Indicateurs indirects; indisponibilité signalée WARN.

Je traite chaque ligne comme un incident déclaré. La couverture, la fréquentation humaine et la sous-déclaration ne sont pas contrôlées.

CE QUE JE NE MESURE PAS
Je ne calcule ni taux d'attaque par personne exposée, ni dangerosité biologique, ni cause d'un incident. Je décris des déclarations et teste des associations.

02 · Architecture et décisions

QUESTION D'ARCHITECTURE
Je construis une chaîne utile, fiable et proportionnée au besoin : l'export source est ponctuel et le volume observé (6 890 lignes) ne justifie pas une plateforme distribuée.

Couche	Rôle dans mon pipeline
Source	CSV GSAF local ou échantillon synthétique
Raw	Copie horodatée UTC, conservée pour diagnostiquer et rejouer
Validation	Profilage, contrat versionné, règles et motifs de rejet
Curated / rejected	Je sépare les lignes acceptées et rejetées; sorties remplaçables
Produit	Rapport JSON, tableaux CSV et visualisations descriptives

Pourquoi batch, fichiers et ce grain ?

Je collecte par batch car la source n'est ni un flux continu ni mise à jour à cadence garantie. Un snapshot raw UTC avec SHA-256 garde la preuve d'entrée. À cette taille, les CSV sont faciles à inspecter; SQLite ajouterait migrations et maintenance sans besoin démontré, tandis que streaming, Warehouse et Mart n'ont pas d'usage mesurable. Le grain est un incident déclaré; sans clé naturelle, je déduplique strictement sur les champs disponibles, avec le risque de fusionner deux événements identiques.

Option	Décision et compromis
CSV batch	Retenu : simple, inspectable, rejouable pour un export ponctuel.
SQLite	Écarté pour l'instant : transactions utiles, mais migrations/maintenance en plus.
Streaming / entrepôt	Écartés : aucune cadence ni intégration ne les justifie.

Je ne conserve pas le CSV réel dans le dépôt : il peut contenir des noms et reste soumis aux conditions du producteur. J'utilise l'échantillon synthétique pour permettre une démonstration reproductible sans divulguer ces données.

La décision est détaillée dans l'ADR 001; les architectures V1 et V2 sont livrées en SVG.

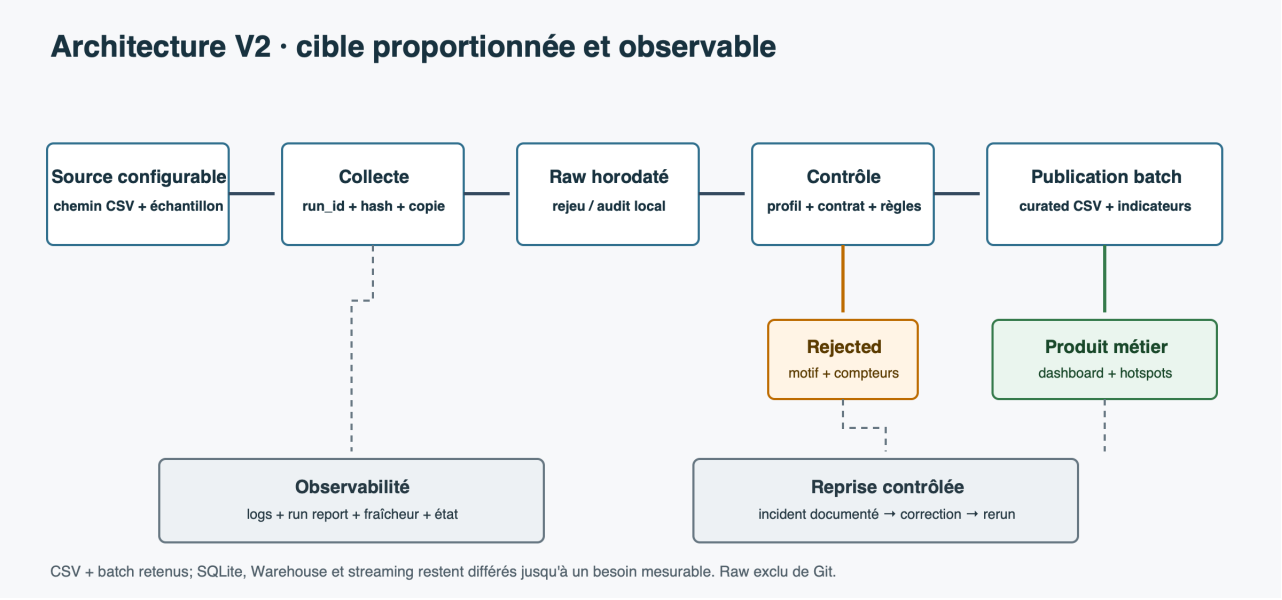
Version	Évolution montrée
V1	Flux source → raw → contrôles → curated / rejets → indicateurs.
V2	Entrée configurable, profilage, schéma, logs, rapport de run et reprise.

HYPOTHÈSES, NON ÉTABLIES
H1-H5 sont des tests d'associations à partir de données disponibles. Aucun résultat ne démontre une cause biologique ou un risque individuel.

Je ne scrape pas le site GSAF et ne contourne pas son authentification. Pour l'analyse réelle, je télécharge l'export Kaggle; sinon, les 121 lignes synthétiques valident le pipeline sans données personnelles et sans accès réseau.

03 · Architecture, qualité et reprise

Architecture V2 · cible proportionnée et observable



CONTRÔLES ET COMPTEURS DU RUN DE RÉFÉRENCE (18/10/2026)
Le traitement s'est terminé normalement : **PASS**. Le contrôle qualité reste **PASS_WITH_WARNINGS**, car 194 lignes ont été rejetées. Ce n'est pas un échec du lancement : le rapport détaille chaque règle et conserve les rejets pour examen.

Run	Entrées	Acceptées	Rejetées	Doublons	État
20261018T122103101173Z	6 890	6 687	194	9	PASS

Contrôle	Échecs / action
Pays	51 · rejet
Année	133 · rejet
Type	20 · rejet
Âge	0 · corrigé à NULL
Unicité	9 · doublons supprimés

Observabilité et reprise

Pour ce run : durée 0,27 s · dernière date d'incident 2023-08-16 · âge de cette date 1 159 jours. La fraîcheur porte sur la date de l'événement, pas celle de publication du fichier. Le rapport conserve run_id, empreinte, compteurs et sorties. J'ai testé une source absente : le pipeline écrit un rapport FAIL et retourne un code d'erreur; après correction de la source, je relance le même point d'entrée.

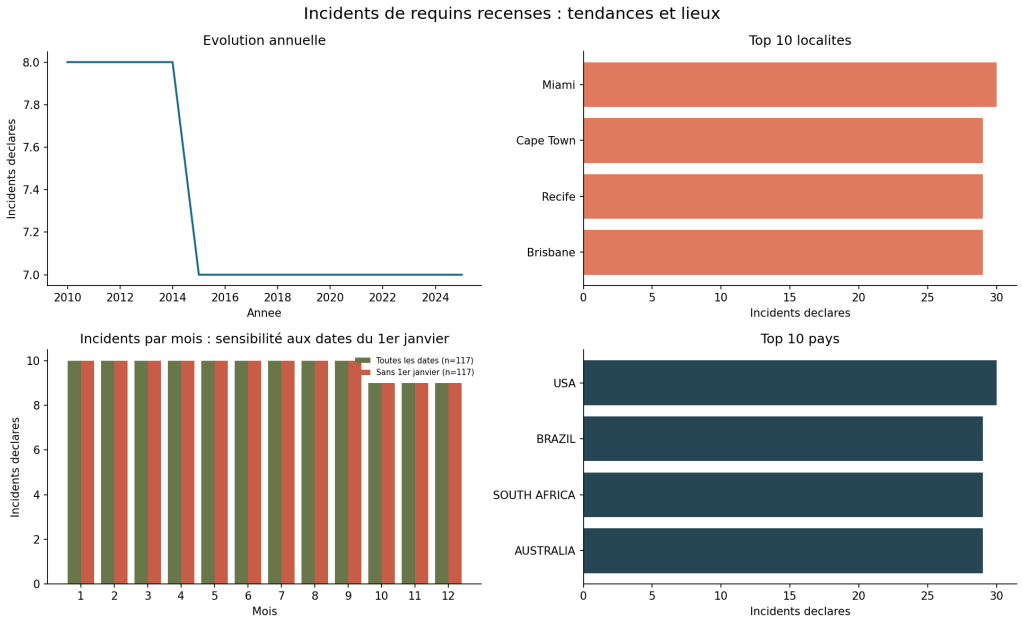
Je remplace les sorties curated/rejected à chaque run; le snapshot raw local sert au rejeu et reste exclu de Git. Le batch CSV est proportionné à l'export (ADR 001); une API météo/NOAA indisponible produit WARN et le cache est réutilisé s'il existe.

Usage d'outils d'IA

J'ai utilisé GitHub Copilot comme aide pour certaines tâches d'implémentation, de documentation et de tests : amélioration du collecteur et de l'orchestrateur, données de démonstration, ADR, architecture et tests. Je reste responsable des choix initiaux et d'implémentation du projet, de la mise en place de la documentation, ainsi que de la compréhension et des choix présentés. J'ai relu et validé chaque modification assistée; le pipeline et les tests ont été exécutés.

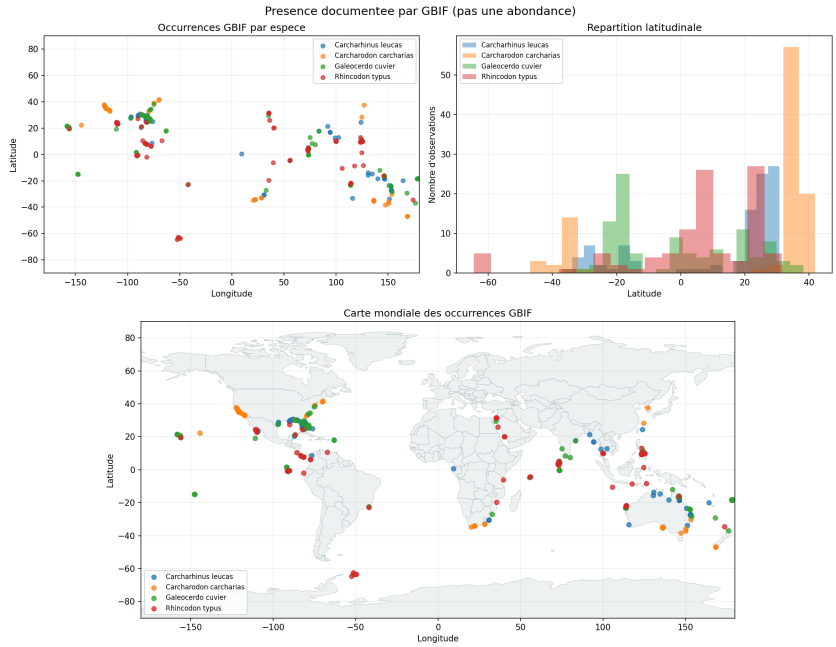
04 · Ce que montrent les données et la carte GBIF

Dans l'export traité, les déclarations culminent autour des années 2010 et **New Smyrna Beach** est la localité connue la plus représentée. Ce sont des comptes de déclarations, sensibles à la fréquentation, à la couverture et aux pratiques de signalement; ils ne mesurent pas un risque.



Sensibilité des dates : 347 dates (5,3 %) sont au 1er janvier. Le mois le plus représenté passe de janvier à juillet quand je les exclue; faute de champ de précision, c'est un test de sensibilité, pas une correction. Sur 6 516 incidents datés, 5 990 ont une activité connue. L'association mois-activité est faible (V de Cramer = 0,083; 5 activités + « Autres »); la rosace normalise chaque activité séparément et ne compare pas leurs volumes ni ne démontre une cause.

Carte des occurrences GBIF : de quelles données suis-je parti ?



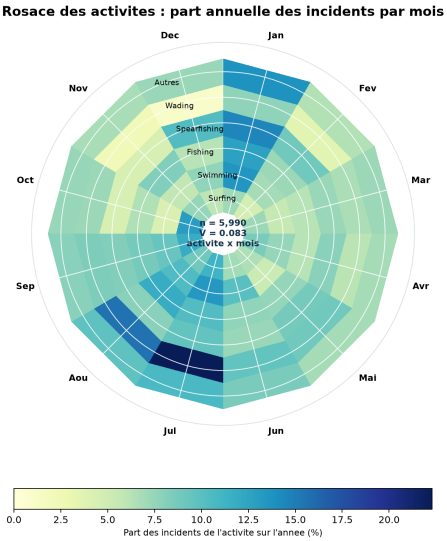
1 · Données d'entrée. Pour chacune des quatre espèces, je résous le nom taxonomique puis interroge GBIF pour les occurrences avec coordonnées (limite de 100 par espèce). J'obtiens quatre CSV locaux, soit 400 lignes (31/01/2025-22/08/2026), avec dates, coordonnées et stades de vie.
2 · Préparation. Je concatène les CSV, convertis les coordonnées en nombres et écarte les lignes sans latitude, longitude ou espèce.
3 · Fond de carte. J'utilise les polygones de pays Natural Earth déjà conservés dans *data/reference/ne_110m_admin_0_countries.geojson*.
4 · Tracé. Avec *python -m src.species_visualize*, Matplotlib colore les points par espèce : nuage longitude/latitude et histogrammes de latitude en haut, carte avec frontières en bas. La figure est *reports/images/species_occurrences.png*.
Limite : le nombre de points n'est pas une mesure d'abondance; il dépend des signalements GBIF et de leur effort d'observation. Ces occurrences récentes ne couvrent pas l'historique des incidents.

Candidate géographique	<= 25 km	<= 100 km / 1 011	Juvéniles <= 100 km
Carcharhinus leucas	469	642 (63,5 %)	534
Carcharodon carcharias	54	116 (11,5 %)	26
Galeocerdo cuvier	53	526 (52,0 %)	24
Rhincodon typus	0	37 (3,7 %)	0

Les rapprochements sont des paires non exclusives : une attaque peut compter pour plusieurs espèces. Une coordonnée d'attaque peut être un centre de localité; une occurrence juvénile ne prouve pas une nurserie. Je parle donc de présence régionale documentée, jamais de l'espèce responsable ou d'une relation temporelle.

05 · Activités, saisonnalité et hypothèses

FAIT OBSERVÉ · SAISONNALITÉ DES ACTIVITÉS
Sur 5 990 incidents datés avec activité connue, l'association mois-activité est faible (V de Cramer = 0,083; cinq activités principales + « Autres »). La rosace montre, pour chaque activité, sa répartition mensuelle normalisée.



Anneaux = activites (5 principales + autres) · chaque anneau totalise 100 %

Je lis chaque anneau séparément : la couleur compare les mois au sein d'une activité, pas le volume entre activités. L'analyse ne contrôle ni le pays, ni l'année, ni la fréquentation; cette association descriptive ne prouve pas une cause.

Hypothèses environnementales : résultats disponibles

DONNÉES INSUFFISANTES POUR CONCLURE
Aucun résultat d'enrichissement SST/météo/témoins n'est disponible localement pour ce rendu. Je n'affiche donc aucun graphique environnemental vide : les cinq tests restent non concluants, avec n=0. Les occurrences GBIF sont présentées séparément comme chevauchements géographiques récents.

Hypothèse / test	Résultat chiffré	Statut final	n
H1 · Température de l'eau SST jour de l'incident vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H2 · Anomalie SST vs climatologie locale	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H3 · Exposition humaine Air, pluie, vent vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H4 · Présence de l'espèce Piste GBIF 2025-2026, exploratoire	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H5 · Pluie antérieure Pluie des 3 jours précédents	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0

H1 : SST le jour de l'incident vs témoins du même lieu et de la même année. H2 : SST vs climatologie locale 1982-2011 (fenêtre de 31 jours). H3 : température max de l'air plus élevée, pluie et vent plus faibles que les témoins; je calcule la saison par hémisphère (décalage de six mois au sud). H4 : piste exploratoire GBIF (occurrences 2025-2026). H5 : pluie des trois jours précédents, indicateur indirect de turbidité. Les tests d'association ne démontrent jamais une cause.

06 · Limites, gouvernance et suite

HYPOTHÈSES, NON ÉTABLIES
Aucune source environnementale ne permet d'établir la cause d'un incident. Les conditions météorologiques et océaniques sont des indicateurs indirects, sensibles à la qualité des dates, coordonnées et témoins.

Limites d'interprétation

Le jeu source est ponctuel, comporte des dates et lieux de précision variable et ne mesure pas l'exposition humaine. Une coordonnée peut représenter un centre de localité. Les témoins et seuils statistiques ne corrigent pas les biais de couverture. Les résultats H1-H5 sont exploratoires et ne permettent pas d'inférer causalité ou risque.

Vie privée et gouvernance

Le champ **name** est exclu des échantillons, du curated et des indicateurs. Le CSV réel et les snapshots raw ne sont pas versionnés. Les âges et lieux peuvent rester réidentifiants par recoupement; je limite donc l'usage au descriptif et conserve les données source localement, sous réserve de licence et de conditions de conservation. Je garde le raw pour le rejeu pendant le projet, puis le supprime ou l'anonymise selon les règles du producteur.

Pistes de suite

La vérification directe des métadonnées ERDDAP NOAA (.html et .das) reste à faire car le serveur n'était pas joignable lors de la génération; enrichir uniquement les incidents géocodés; évaluer les analyses quand les données environnementales sont présentes; conserver les statuts WARN et les limites visibles dans chaque restitution.

Reproductibilité et transparence

Les tests utilisent des fixtures et mocks, sans appels réseau; l'échantillon synthétique de 121 lignes permet de rejouer le pipeline localement. Je vérifie les sorties avant de les interpréter et documente les limites des sources.

Pour approfondir	Fichier ou commande
Installer et relancer	README.md (macOS, Linux, PowerShell, cmd) · python -m src.pipeline · python -m pytest -q
Architecture	docs/architecture.md · docs/architecture_v1.svg · docs/architecture_v2.svg
Règles et champs	config/data_contract.yaml · docs/data_dictionary.md
Sources et méthodes environnementales	docs/source_assessment.md · docs/ADR_002.md
Choix de stockage	docs/ADR_001.md
Test d'incident et gouvernance	docs/incident_test.md · docs/rgpd_audit.md
Code du dépôt	github.com/noahgog25/shark-attacks-collector

Ce que je livre

Je produis un CSV curated sans nom, les lignes rejetées avec leur motif, un profil source, un rapport de run, des tableaux de hotspots et de saisonnalité, des visualisations et cette synthèse. Une autre personne peut reprendre les commandes depuis le README dans un environnement propre; la démonstration tient dans le pipeline et ses sorties. Le raw réel reste exclu de Git; je vérifie les droits de redistribution et les règles de conservation avant toute remise.

Je ne versionne ni le CSV réel ni la colonne name. Les graphiques environnementaux seront mis à jour uniquement à partir de données enrichies effectivement disponibles.