Shark Attacks Collector

LANCER LE PROJET EN 5 MINUTES
1. Installer Python 3.11+ et les dépendances de **requirements.txt**.
2. Télécharger l'export GSAF depuis Kaggle, le renommer **global_shark_attacks_raw.csv** et le placer dans **data/raw/**.
3. Depuis la racine : **python -m src.pipeline**, puis **python -m pytest -q**.
Sans export réel, le jeu synthétique de 121 lignes valide le parcours local.

01 · Question et périmètre

Où et quand les incidents de requins sont-ils déclarés ?
Dans quelles conditions environnementales les signalements surviennent-ils ?
Que peut-on tester sans confondre association, cause et risque individuel ?

FAIT OBSERVÉ · dernier run réel de référence
6 890 entrées -> 6 687 acceptées, 194 rejetées et 9 doublons retirés (PASS). Ces nombres décrivent un export ponctuel, pas le risque de morsure ni l'ensemble des incidents réels.

Ce que je cherche à produire

Je construis un pipeline reproductible qui transforme les déclarations GSAF en fichiers contrôlés et indicateurs descriptifs, puis teste avec prudence des pistes environnementales. Aucune API ne fournit la cause d'une attaque.

Besoin	Indicateur livré
Choisir des lieux ou périodes à examiner	Comptes par pays, localité, année et mois
Comparer une saisonnalité	Mois, avec sensibilité aux dates du 1er janvier
Formuler des pistes environnementales	H1-H5, tests et statuts explicites

Je traite chaque ligne comme un incident déclaré. La couverture, la fréquentation humaine et la sous-déclaration ne sont pas contrôlées.

02 · Besoin, usages et sources

FAIT OBSERVÉ
Le GSAF est un export déclaré et ponctuel. Les compteurs décrivent son contenu et dépendent aussi de la couverture et des pratiques de signalement.

Usage	Question explorée	Indicateur
Localiser	Où les déclarations sont-elles nombreuses ?	Comptes par lieu et pays
Comparer les périodes	Comment les déclarations varient-elles ?	Comptes par année et mois
Tester l'environnement	Quelles conditions coïncident avec les dates ?	SST, anomalie, météo et témoins

Sources retenues

Source	Usage et précaution
Global Shark Attack File (Kaggle)	CSV source pour les incidents; accès ponctuel, licence et redistribution à vérifier.
NOAA OISST v2.1 / ERDDAP	Jeu ncdcOisst21Agg_LonPM180; une requête par cellule unique sur 1982-2023, grille 0,25°. Climatologie locale 1982-2011, fenêtre de 31 jours; repli côtier si cellule terrestre.
Open-Meteo Archive (ERA5)	Température max, pluie et vent; données météo indirectes, attribution CC BY 4.0.
GBIF	Occurrences 2025-2026 conservées comme piste exploratoire, sans attribution d'espèce responsable.

HYPOTHÈSES, NON ÉTABLIES
H1-H5 sont des tests d'associations à partir de données disponibles. Aucun résultat ne démontre une cause biologique ou un risque individuel.

Je ne scrape pas le site GSAF et ne contourne pas son authentification. Le CSV réel et les champs identifiants restent locaux et hors Git; l'échantillon synthétique permet de tester le pipeline sans réseau.

03 · Architecture, qualité et reprise

Un batch local, lisible et rejouable

Source CSV	Snapshot raw UTC	Validation	Curated + rejets	Rapports
GSAF local ou sample	Copie + SHA-256	5 règles + compteurs	Séparation des lignes	CSV, PNG, JSON

FAIT OBSERVÉ · dernier run réel de référence
PASS opérationnel; le statut qualité est assorti d'avertissements parce que les rejets sont conservés et comptabilisés.

Contrôle	Résultat	Traitement
Pays	51	Rejet si absent
Année	133	Rejet si hors plage
Type	20	Rejet si catégorie inconnue
Âge	0	Valeur suspecte corrigée à NULL
Unicité	9	Doublons stricts supprimés et comptés

Entrées	Acceptées	Rejetées	Doublons	Dernière date
6 890	6 687	194	9	2023-08-16

Traçabilité et reprise

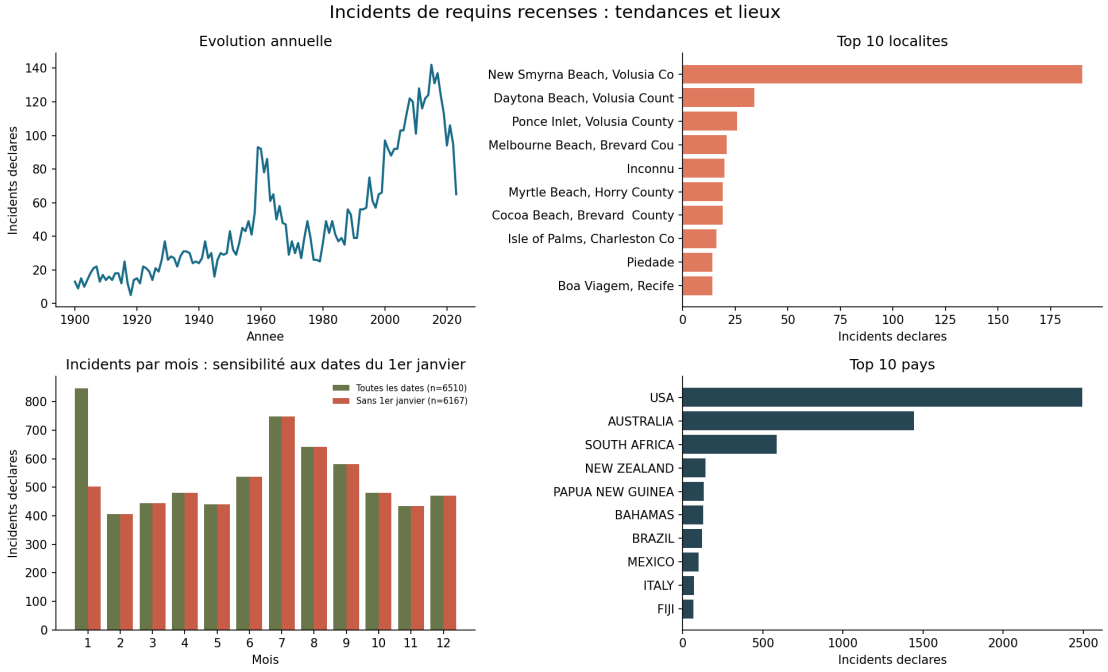
Chaque run journalise un identifiant, l'empreinte et la taille de la source, les compteurs, la durée et les sorties. Un test de source absente vérifie le rapport FAIL et le code d'échec; après correction, le pipeline peut être relancé. Les CSV curated et rejected sont remplacés à chaque exécution, tandis que les snapshots raw servent au rejeu.

Le CSV suffit à un export ponctuel de cette taille. Je n'introduis ni entrepôt ni streaming sans besoin mesurable; SQLite reste une option si les usages SQL augmentent. Les caches NOAA et météo sont locaux; une API indisponible produit un statut WARN.

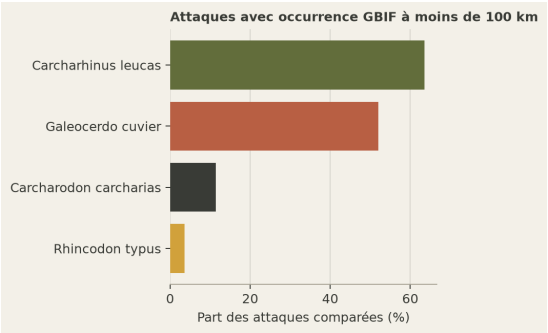
Le snapshot raw conserve les données source : il reste local, ignoré par Git et à supprimer ou anonymiser selon les conditions du producteur.

04 · Ce que montrent les données

FAIT OBSERVÉ · incidents déclarés
Le tableau de bord résume des comptes contenus dans le fichier. Les évolutions peuvent aussi refléter la fréquentation humaine, la couverture et la déclaration.



Lecture du graphique annuel : les signalements culminent autour des années 2010; la baisse récente ne prouve pas une baisse des événements réels. **Lecture du graphique mensuel :** janvier est le mois le plus représenté toutes dates confondues; en excluant les 1ers janvier, juillet devient le plus représenté.



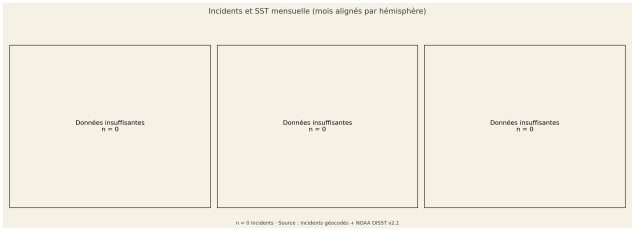
FAIT OBSERVÉ · rapprochement GBIF
1 011 lieux d'attaque géocodés comparés; occurrences dans un rayon de 100 km :
Carcharhinus leucas : 642 · **Galeocerdo cuvier :** 526
Carcharodon carcharias : 116 · **Rhincodon typus :** 37
Limite : une attaque peut être proche de plusieurs espèces; l'effort d'observation varie. Ces proximités ne prouvent ni la présence le jour de l'incident ni l'espèce responsable.

05 · Hypothèses environnementales

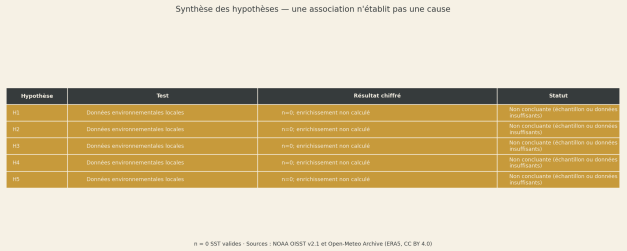
HYPOTHÈSES, NON ÉTABLIES
Les graphiques portent la taille d'échantillon et la source. Sans données enrichies disponibles, ils affichent n=0 et les statuts restent non concluants; aucune donnée n'est inventée pour remplir les figures.











Hypothèse / test	Résultat chiffré	Statut final	n
H1 · Température de l'eau SST jour de l'incident vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H2 · Anomalie SST vs climatologie locale	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H3 · Exposition humaine Air, pluie, vent vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H4 · Présence de l'espèce Piste GBIF 2025-2026, exploratoire	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H5 · Pluie antérieure Pluie des 3 jours précédents	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0

Lecture prudente : H1 compare la SST aux témoins du même lieu et de la même année; H2 compare la SST à une climatologie locale (1982-2011, fenêtre de 31 jours); H3 compare météo et témoins, avec saison calculée par hémisphère; H4 reste exploratoire (GBIF 2025-2026); H5 teste la pluie des trois jours précédents comme indicateur indirect de turbidité. Une association n'est pas une cause.

06 · Limites, gouvernance et suite

HYPOTHÈSES, NON ÉTABLIES
Aucune source environnementale ne permet d'établir la cause d'un incident. Les conditions météorologiques et océaniques sont des indicateurs indirects, sensibles à la qualité des dates, coordonnées et témoins.

Limites d'interprétation

Le jeu source est ponctuel, comporte des dates et lieux de précision variable et ne mesure pas l'exposition humaine. Une coordonnée peut représenter un centre de localité. Les témoins et seuils statistiques ne corrigent pas les biais de couverture. Les résultats H1-H5 sont exploratoires et ne permettent pas d'inférer causalité ou risque.

Vie privée et gouvernance

Le champ **name** est exclu des échantillons, du curated et des indicateurs. Le CSV réel et les snapshots raw ne sont pas versionnés. Les âges et lieux peuvent rester réidentifiants par recoupement; je limite donc l'usage au descriptif et conserve les données source localement, sous réserve de licence et de conditions de conservation.

Pistes de suite

La vérification directe des métadonnées ERDDAP NOAA (.html et .das) reste à faire car le serveur n'était pas joignable lors de la génération; enrichir uniquement les incidents géocodés; évaluer les analyses quand les données environnementales sont présentes; conserver les statuts WARN et les limites visibles dans chaque restitution.

Reproductibilité et transparence

Les tests utilisent des fixtures et mocks, sans appels réseau. L'échantillon synthétique de 121 lignes permet une exécution locale. GitHub Copilot a aidé à l'implémentation, à la documentation et aux tests; les choix, vérifications et déclarations personnelles restent à la charge de l'étudiant.

Pour approfondir	Fichier ou commande
Installer et relancer	README.md · python -m src.pipeline · python -m pytest -q
Architecture et règles	docs/architecture.md · config/data_contract.yaml
Sources et méthodes environnementales	docs/source_assessment.md · docs/ADR_002.md
Dictionnaire et limites	docs/data_dictionary.md · docs/rgpd_audit.md
Code du dépôt	github.com/noahgog25/shark-attacks-collector

Je ne versionne ni le CSV réel ni la colonne name. Les graphiques environnementaux seront mis à jour uniquement à partir de données enrichies effectivement disponibles.