Shark Attacks Collector

Synthèse du projet final · Architecture BD et collecte de données

1 · Problème, usage et sources

Le projet transforme des incidents déclarés dans le Global Shark Attack File (GSAF) en données contrôlées et en indicateurs descriptifs. L'utilisateur cible est un étudiant, un enseignant ou un analyste qui veut repérer les lieux et périodes à examiner, sans confondre fréquence de signalement et dangerosité biologique.

Question centrale

Où et quand les incidents de requins sont-ils recensés, et quelles espèces sont candidates dans les régions où une présence GBIF est documentée ?

Cas d'usage	Indicateur
Repérer les lieux les plus souvent déclarés	Nombre d'incidents par localité, pays et année
Examiner les variations saisonnières	Nombre d'incidents par mois
Orienter une recherche écologique	Proximités attaque-occurrence à 25 km et 100 km

Source et conformité

La source principale est un export CSV GSAF obtenu via Kaggle; sa mise à jour est ponctuelle et son accès peut demander une session. Le collecteur ne scrape pas le site et ne contourne pas l'authentification. Les conditions exactes de redistribution doivent être confirmées avant publication. Le CSV réel contenant des noms reste local et ignoré par Git. Un échantillon synthétique de 121 lignes permet la démonstration depuis un clone propre.

Le grain est un incident déclaré. La source n'offre pas de clé naturelle; la déduplication stricte sur tous les champs est reproductible mais peut fusionner deux incidents identiques. La fréquence est batch et ponctuelle, car la source n'est pas un flux continu.

2 · Chaîne et architecture

Le choix est une chaîne locale simple : le coût d'exploitation reste faible, chaque étape est inspectable et le volume du jeu (6 890 observations réelles dans le dernier run vérifié) ne justifie pas de plateforme distribuée.

Étape	Entrée / action	Sortie / preuve
Collecte	CSV local, chemin CLI ou échantillon	Snapshot UTC non transformé, SHA-256
Profil	Snapshot brut	Dimensions, types, manquants, doublons, modalités
Qualité	Schéma source	Acceptés, rejetés, compteurs par règle
Transformation	Lignes acceptées	CSV curated normalisé et typé
Publication	Curated	Dashboard PNG, hotspots et saisonnalité CSV
Observabilité	Chaque run	run_id, logs, rapport PASS/FAIL, durée, fraîcheur

Architecture V1 et évolution V2

La V1 représente le flux source → raw → validation → curated/rejected → restitution. La V2 ajoute l'entrée configurable, les contrôles de schéma, les logs et le rapport de run, ainsi que le chemin de reprise après incident. Les deux diagrammes SVG livrés dans docs/ sont les vues de référence.

Stockage et choix écartés

Les fichiers CSV suffisent à un lot ponctuel et facilitent l'inspection. SQLite apporterait transactions, contraintes et requêtes SQL, mais demanderait migrations et maintenance sans bénéfice nécessaire à ce volume. Warehouse, Lake séparé et streaming sont écartés faute d'intégrations durables ou d'exigence de latence. L'ADR 001 détaille les compromis et les conditions de réexamen.

Les snapshots raw permettent le rejeu; curated et rejected sont remplacés à chaque run. Les observations écologiques restent séparées et les distances sont interprétées comme candidatures géographiques, jamais comme identification de l'espèce responsable.

3 · Qualité, robustesse et observabilité

Le contrat versionné fixe le grain, le schéma et cinq règles automatisées :

Règle	Dimension / action
completude_pays	Complétude : rejeter pays absent
validite_annee	Validité : rejeter année hors plage
coherence_type	Cohérence : rejeter catégorie inconnue
domaine_age	Domaine : corriger l'âge suspect à NULL
unicite	Unicité : supprimer les doublons stricts et compter

Dernière exécution réelle vérifiée

Métrique	Valeur
État	PASS_WITH_WARNINGS
Entrées / acceptées / rejetées	6890 / 6687 / 194
Doublons retirés	9
Date source la plus récente	2023-08-16
Âge de cette observation (jours)	1159
Durée	0.26 s
Run ID	20261018T120038724349Z

Incident et reprise

Un test simule une source absente : le processus échoue, conserve le rapport FAIL avec run_id, type et message, puis une source valide est fournie et une nouvelle exécution passe. Un CSV vide ou un schéma privé des champs requis est refusé avant publication. Le snapshot brut déjà créé est gardé pour diagnostic. Les logs décrivent début, collecte, qualité, fin ou exception.

La métrique de fraîcheur est calculée à partir de la date d'incident maximale; elle ne mesure pas le délai de publication de Kaggle. L'export source est ponctuel et ne permet pas d'affirmer une fraîcheur de collecte amont.

4 · Produit de données et décision

Le produit final sert à explorer les incidents déclarés par année, pays, localité et mois. Le dashboard présente la tendance temporelle, la saisonnalité et les principaux lieux; les CSV de hotspots et de saisonnalité permettent une réutilisation directe. Le curated expose des dates, lieux, activités, catégories, sexe et classes d'âge nettoyés.

Artefact	Usage
data/curated/shark_attacks_curated.csv	Table analytique propre; sans nom de victime
data/rejected/rejected_rows.csv	Audit des lignes rejetées et raison
reports/images/dashboard_incidents.png	Restitution visuelle synthétique
reports/data/hotspots_incidents_declares.csv	Comptes par lieux déclarés
reports/data/saisonnalite_incidents_declares.csv	Comptes mensuels déclarés
reports/interpretation/run_report.json	Provenance, état, mesures et sorties du run

Décisions permises et limites d'interprétation

Les tableaux aident à prioriser des zones/périodes pour une étude complémentaire. Ils ne mesurent pas un risque individuel ou une dangerosité intrinsèque : fréquentation humaine, couverture et sous-déclaration ne sont pas contrôlées. Les proximités GBIF ne prouvent ni l'espèce attaquante ni une causalité écologique.

Les fichiers synthétiques livrés couvrent 121 lignes source, dont des cas invalides et un doublon; ils servent au test de bout en bout, pas à tirer des conclusions biologiques. L'export réel est conservé localement et son partage doit respecter licence et minimisation.

Résultat reproductible

Un nouvel utilisateur crée un environnement Python 3.11+, installe requirements.txt puis lance python -m src.pipeline et python -m pytest tests/. Le pipeline sélectionne l'export réel local s'il est présent, sinon l'exemple synthétique. Le script scripts/build_demo_data.py régénère les exemples raw, curated et rejected.

5 · Gouvernance, risques et perspectives

Données personnelles et conservation

Le champ name est identifiant et inutile aux indicateurs : il est exclu du curated et des visualisations. Le CSV réel et les snapshots raw sont ignorés par Git. Les âges et lieux peuvent encore être réidentifiants par recoupement; l'accès reste local et la finalité est descriptive. Le raw doit être supprimé ou anonymisé à la fin du projet, sous réserve des conditions du producteur. La base légale et la licence de redistribution doivent être confirmées par l'étudiant avec l'enseignant.

Compromis et améliorations

Une clé naturelle absente impose une déduplication stricte imparfaite. Les sorties fichiers n'offrent pas de transaction commune; une interruption en publication peut demander un rejeu complet. Les pistes utiles sont une publication atomique, SQLite si l'usage SQL croît, et une deuxième source officielle dont la complémentarité est démontrée. Streaming et orchestration sont différés tant qu'aucune cadence ne les justifie.

Usage d'outils d'IA

GitHub Copilot a assisté l'implémentation, la rédaction documentaire et la revue des tests. Les changements ont été vérifiés par exécution du pipeline et des tests automatisés. Avant remise, l'étudiant doit compléter le README en indiquant les parties qu'il a personnellement relues, comprises et adaptées; cette déclaration ne peut être inventée par l'outil.

Livraison

Le dépôt contient le code, les tests, le contrat, le dictionnaire, les architectures SVG, l'ADR, le test d'incident, les données d'exemple et cette synthèse PDF. Avant dépôt sur Moodle, vérifier l'accès au dépôt, confirmer les droits sur l'export réel, compléter la déclaration personnelle d'usage de l'IA et rejouer les commandes depuis un environnement propre.

Références de travail : README.md · docs/ADR_001.md · docs/architecture.md · docs/incident_test.md · config/data_contract.yaml · docs/rgpd_audit.md