Shark Attacks Collector

LANCER LE PROJET EN 5 MINUTES
1. Installer Python 3.11+ et les dépendances de **requirements.txt**.
2. Télécharger l'export GSAF depuis Kaggle, le renommer **global_shark_attacks_raw.csv** et le placer dans **data/raw/**.
3. Depuis la racine : **python -m src.pipeline**, puis **python -m pytest -q**.
Sans export réel, le jeu synthétique de 121 lignes valide le parcours local.

01 · Question et périmètre

Où et quand les incidents de requins sont-ils déclarés ?
Dans quelles conditions environnementales les signalements surviennent-ils ?
Que peut-on tester sans confondre association, cause et risque individuel ?

FAIT OBSERVÉ · dernier run réel de référence
6 890 entrées -> 6 687 acceptées, 194 rejetées et 9 doublons retirés (PASS). Ces nombres décrivent un export ponctuel, pas le risque de morsure ni l'ensemble des incidents réels.

Ce que je cherche à produire

Je construis un pipeline reproductible qui transforme les déclarations GSAF en fichiers contrôlés et indicateurs descriptifs, puis teste avec prudence des pistes environnementales. Aucune API ne fournit la cause d'une attaque.

Besoin	Indicateur livré
Choisir des lieux ou périodes à examiner	Comptes par pays, localité, année et mois
Comparer une saisonnalité	Mois, avec sensibilité aux dates du 1er janvier
Formuler des pistes environnementales	H1-H5, tests et statuts explicites

Je traite chaque ligne comme un incident déclaré. La couverture, la fréquentation humaine et la sous-déclaration ne sont pas contrôlées.

02 · Besoin, usages et sources

FAIT OBSERVÉ
Le GSAF est un export déclaré et ponctuel. Les compteurs décrivent son contenu et dépendent aussi de la couverture et des pratiques de signalement.

Usage	Question explorée	Indicateur
Localiser	Où les déclarations sont-elles nombreuses ?	Comptes par lieu et pays
Comparer les périodes	Comment les déclarations varient-elles ?	Comptes par année et mois
Tester l'environnement	Quelles conditions coïncident avec les dates ?	SST, anomalie, météo et témoins

Sources retenues

Source	Usage et précaution
Global Shark Attack File (Kaggle)	CSV source pour les incidents; accès ponctuel, licence et redistribution à vérifier.
NOAA OISST v2.1 / ERDDAP	Jeu ncdcOisst21Agg_LonPM180; une requête par cellule unique sur 1982-2023, grille 0,25°. Climatologie locale 1982-2011, fenêtre de 31 jours; repli côtier si cellule terrestre.
Open-Meteo Archive (ERA5)	Température max, pluie et vent; données météo indirectes, attribution CC BY 4.0.
GBIF	Occurrences 2025-2026 conservées comme piste exploratoire, sans attribution d'espèce responsable.
Nominatim / OpenStreetMap	Géocodage ponctuel des lieux textuels; une coordonnée peut être un centre-ville, pas un point GPS d'incident.

Mes choix de collecte et de stockage

Je traite un lot ponctuel : l'export source n'est pas un flux et sa fréquence de mise à jour n'est pas garantie. Je conserve un snapshot raw UTC avec son SHA-256 pour pouvoir rejouer le pipeline; à 6 890 lignes, les CSV locaux sont inspectables sans ajouter une base de données. Le grain est un incident déclaré. Faute de clé naturelle, je supprime les doublons stricts sur les champs disponibles : cette règle est reproductible, mais pourrait fusionner deux événements distincts dont les valeurs seraient identiques.

HYPOTHÈSES, NON ÉTABLIES
H1-H5 sont des tests d'associations à partir de données disponibles. Aucun résultat ne démontre une cause biologique ou un risque individuel.

Je ne scrape pas le site GSAF et ne contourne pas son authentification. Je télécharge l'export Kaggle si je veux lancer l'analyse réelle; sinon, l'échantillon synthétique de 121 lignes valide le parcours local sans accès réseau.

03 · Architecture, qualité et reprise

Un batch local, lisible et rejouable

Source CSV	Snapshot raw UTC	Validation	Curated + rejets	Rapports
GSAF local ou sample	Copie + SHA-256	5 règles + compteurs	Séparation des lignes	CSV, PNG, JSON

FAIT OBSERVÉ · dernier run réel de référence
PASS opérationnel; le statut qualité est assorti d'avertissements parce que les rejets sont conservés et comptabilisés.

Contrôle	Résultat	Traitement
Pays	51	Rejet si absent
Année	133	Rejet si hors plage
Type	20	Rejet si catégorie inconnue
Âge	0	Valeur suspecte corrigée à NULL
Unicité	9	Doublons stricts supprimés et comptés

Entrées	Acceptées	Rejetées	Doublons	Dernière date
6 890	6 687	194	9	2023-08-16

Qualité	Règle / traitement
51 pays manquants; 133 années hors plage; 20 types inconnus	Lignes rejetées avec motif
0 correction d'âge	Âge suspect corrigé à NULL
9 doublons stricts	Retirés et comptés

Traçabilité et reprise

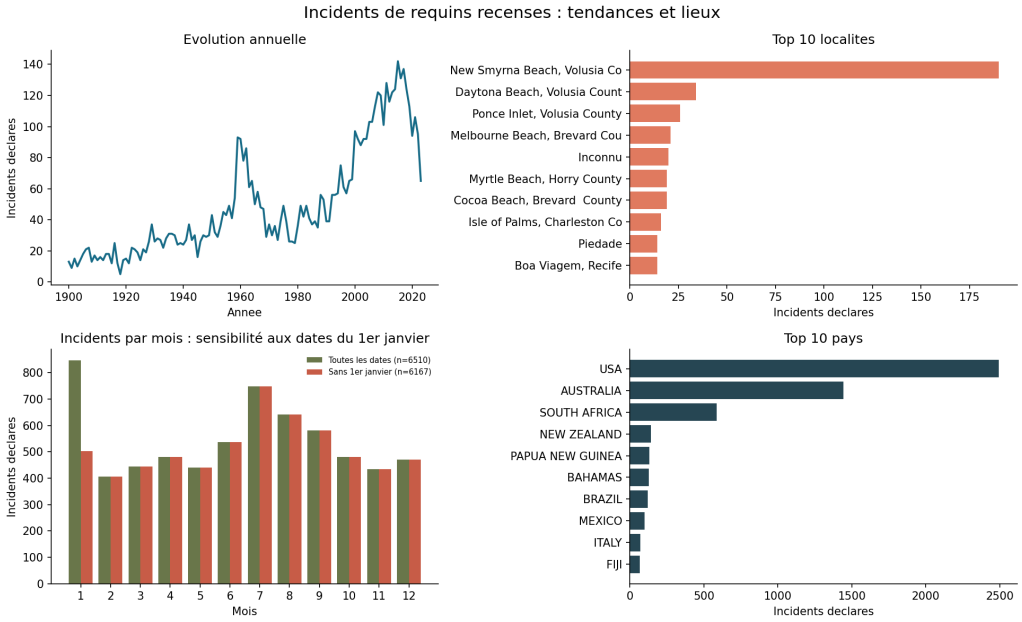
Mon run de référence est **20261026T1354598437 61Z** : durée 0,28 s, dernière date d'incident 2023-08-16 et âge de cette date 1 167 jours au moment du run. La fraîcheur mesure la date de l'événement, pas la date de publication de l'export. Le rapport garde run_id, SHA-256, taille, compteurs, profil source et sorties. Un test de source absente vérifie l'écriture d'un rapport FAIL et le code d'échec; après correction, je relance le pipeline.

La V1 décrit source → raw → contrôles → curated/rejets → indicateurs; la V2 ajoute profilage, schéma, entrée configurable, logs et rapport de run. Je n'ajoute pas d'entrepôt ou de streaming sans besoin mesurable; SQLite reste une option si les usages SQL augmentent. Les CSV curated/rejected sont remplacés à chaque run, les snapshots raw servent au rejeu. Une API météo ou NOAA indisponible laisse le pipeline continuer avec un statut WARN et le cache s'il existe.

Le snapshot raw conserve les données source : il reste local, ignoré par Git et à supprimer ou anonymiser selon les conditions du producteur.

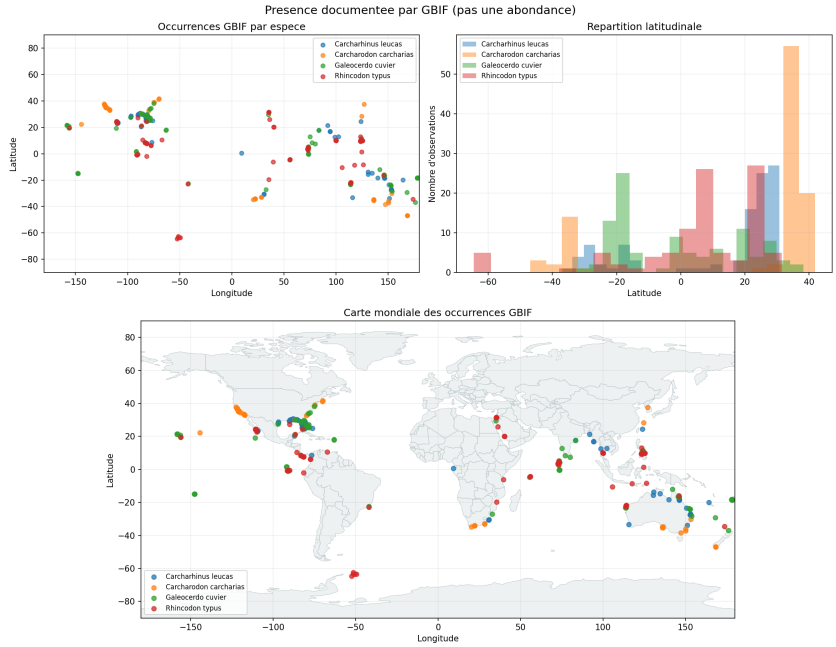
04 · Ce que montrent les données et la carte GBIF

Dans l'export traité, les déclarations culminent autour des années 2010 et **New Smyrna Beach** est la localité connue la plus représentée. Ce sont des comptes de déclarations, sensibles à la fréquentation, à la couverture et aux pratiques de signalement; ils ne mesurent pas un risque.



Sensibilité des dates : 347 dates (5,3 %) sont au 1er janvier. Le mois le plus représenté passe de janvier à juillet quand je les exclue; faute de champ de précision, c'est un test de sensibilité, pas une correction. Sur 6 516 incidents datés, 5 990 ont une activité connue. L'association mois-activité est faible (V de Cramer = 0,083; 5 activités + « Autres »); la rosace normalise chaque activité séparément et ne compare pas leurs volumes ni ne démontre une cause.

Carte des occurrences GBIF : de quelles données suis-je parti ?



1 · Données d'entrée. Pour chacune des quatre espèces, je résous le nom taxonomique puis interroge GBIF pour les occurrences avec coordonnées (limite de 100 par espèce). J'obtiens quatre CSV locaux, soit 400 lignes (31/01/2025-22/08/2026), avec dates, coordonnées et stades de vie.
2 · Préparation. Je concatène les CSV, convertis les coordonnées en nombres et écarte les lignes sans latitude, longitude ou espèce.
3 · Fond de carte. J'utilise les polygones de pays Natural Earth déjà conservés dans *data/reference/ne_110m_admin_0_countries.geojson*.
4 · Tracé. Avec *python -m src.species_visualize*, Matplotlib colore les points par espèce : nuage longitude/latitude et histogrammes de latitude en haut, carte avec frontières en bas. La figure est *reports/images/species_occurrences.png*.
Limite : le nombre de points n'est pas une mesure d'abondance; il dépend des signalements GBIF et de leur effort d'observation. Ces occurrences récentes ne couvrent pas l'historique des incidents.

Candidate géographique	<= 25 km	<= 100 km / 1 011	Juvéniles <= 100 km
Carcharhinus leucas	469	642 (63,5 %)	534
Carcharodon carcharias	54	116 (11,5 %)	26
Galeocerdo cuvier	53	526 (52,0 %)	24
Rhincodon typus	0	37 (3,7 %)	0

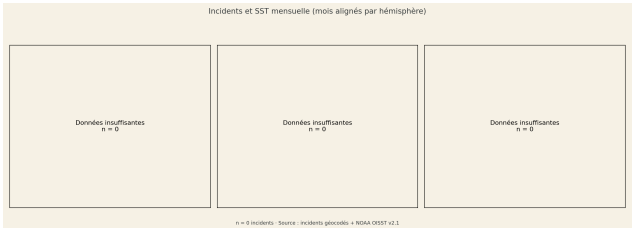
Les rapprochements sont des paires non exclusives : une attaque peut compter pour plusieurs espèces. Une coordonnée d'attaque peut être un centre de localité; une occurrence juvénile ne prouve pas une nurserie. Je parle donc de présence régionale documentée, jamais de l'espèce responsable ou d'une relation temporelle.

05 · Hypothèses environnementales

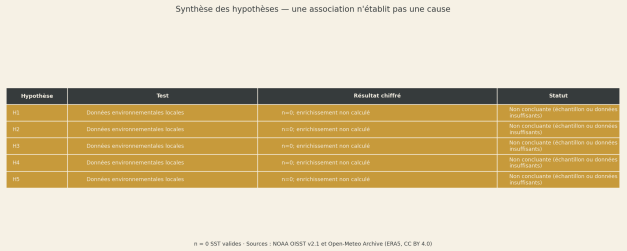
HYPOTHÈSES, NON ÉTABLIES
Les graphiques portent la taille d'échantillon et la source. Sans données enrichies disponibles, ils affichent n=0 et les statuts restent non concluants; aucune donnée n'est inventée pour remplir les figures.











Hypothèse / test	Résultat chiffré	Statut final	n
H1 · Température de l'eau SST jour de l'incident vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H2 · Anomalie SST vs climatologie locale	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H3 · Exposition humaine Air, pluie, vent vs témoins	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H4 · Présence de l'espèce Piste GBIF 2025-2026, exploratoire	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0
H5 · Pluie antérieure Pluie des 3 jours précédents	n=0; données non calculées	Non concluante (échantillon ou données insuffisants)	0

Lecture prudente : H1 compare la SST aux témoins du même lieu et de la même année; H2 compare la SST à une climatologie locale (1982-2011, fenêtre de 31 jours); H3 compare météo et témoins, avec saison calculée par hémisphère; H4 reste exploratoire (GBIF 2025-2026); H5 teste la pluie des trois jours précédents comme indicateur indirect de turbidité. Une association n'est pas une cause.

06 · Limites, gouvernance et suite

HYPOTHÈSES, NON ÉTABLIES
Aucune source environnementale ne permet d'établir la cause d'un incident. Les conditions météorologiques et océaniques sont des indicateurs indirects, sensibles à la qualité des dates, coordonnées et témoins.

Limites d'interprétation

Le jeu source est ponctuel, comporte des dates et lieux de précision variable et ne mesure pas l'exposition humaine. Une coordonnée peut représenter un centre de localité. Les témoins et seuils statistiques ne corrigent pas les biais de couverture. Les résultats H1-H5 sont exploratoires et ne permettent pas d'inférer causalité ou risque.

Vie privée et gouvernance

Le champ **name** est exclu des échantillons, du curated et des indicateurs. Le CSV réel et les snapshots raw ne sont pas versionnés. Les âges et lieux peuvent rester réidentifiants par recoupement; je limite donc l'usage au descriptif et conserve les données source localement, sous réserve de licence et de conditions de conservation.

Pistes de suite

La vérification directe des métadonnées ERDDAP NOAA (.html et .das) reste à faire car le serveur n'était pas joignable lors de la génération; enrichir uniquement les incidents géocodés; évaluer les analyses quand les données environnementales sont présentes; conserver les statuts WARN et les limites visibles dans chaque restitution.

Reproductibilité et transparence

Les tests utilisent des fixtures et mocks, sans appels réseau. L'échantillon synthétique de 121 lignes permet une exécution locale. GitHub Copilot a aidé à l'implémentation, à la documentation et aux tests; les choix, vérifications et déclarations personnelles restent à la charge de l'étudiant.

Pour approfondir	Fichier ou commande
Installer et relancer	README.md (macOS, Linux, PowerShell, cmd) · python -m src.pipeline · python -m pytest -q
Architecture	docs/architecture.md · docs/architecture_v1.svg · docs/architecture_v2.svg
Règles et champs	config/data_contract.yaml · docs/data_dictionary.md
Sources et méthodes environnementales	docs/source_assessment.md · docs/ADR_002.md
Choix de stockage	docs/ADR_001.md
Test d'incident et gouvernance	docs/incident_test.md · docs/rgpd_audit.md
Code du dépôt	github.com/noahgog25/shark-attacks-collector

Ce que je livre

Je produis un CSV curated sans nom, les lignes rejetées avec leur motif, un profil source, un rapport de run, des tableaux de hotspots et de saisonnalité, des visualisations et cette synthèse. Le raw réel reste exclu de Git; je vérifie les droits de redistribution et les règles de conservation avant toute remise.

Je ne versionne ni le CSV réel ni la colonne name. Les graphiques environnementaux seront mis à jour uniquement à partir de données enrichies effectivement disponibles.